RAPPORT FINAL — APPRENTISSAGE PAR RENFORCEMENT SUR *FrozenLake*

A PREPRINT

Ibrahim R. HADJ-ARAB
Faculté des sciences et de génie
Université Laval
ibrahim-rabah.hadj-arab.1@ulaval.ca

Khalil EN NOUAARY
Faculté des sciences et de génie
Université Laval
khalil.en-nouaary.1@ulaval.ca

1er mai 2026

Code source disponible à : `https://github.com/Ribraba/IFT-7201-Projet`

1 Cas d'étude

1.1 Composantes de l'environnement

FrozenLake-v1 [Towers et al., 2024] est un environnement de navigation en grille $N \times N$. L'espace d'états est l'ensemble des N^2 cases, représenté par un entier $s \in \{0, \ldots, N^2 - 1\}$ (numérotation de gauche à droite et de haut en bas) ; l'espace d'actions contient quatre déplacements (haut, bas, gauche, droite). Trois composantes peuvent être manipulées pour moduler la difficulté :

- **Degré de stochasticité :** le paramètre `is_slippery` contrôle la dynamique de transition. Lorsque activé, chaque action entraîne le déplacement souhaité avec probabilité $1/3$ et l'un des deux déplacements perpendiculaires avec probabilité $1/3$ chacun.
- **Nombre de situations dangereuses :** les cases de type `H` (trous) constituent les situations dangereuses. Augmenter leur nombre réduit la surface praticable et multiplie les risques de chute.
- **Positionnement des situations dangereuses :** regrouper les trous de façon contiguë crée un obstacle de type falaise, forçant l'agent à choisir entre un chemin court risqué et un détour sûr.

Un épisode se termine lorsque l'agent atteint l'objectif `G`, tombe dans un trou `H`, ou dépasse 200 pas de temps. La fonction de récompense est mise en forme (*reward shaping*) pour densifier le signal d'apprentissage et rendre les comportements indésirables plus visibles empiriquement [Ng et al., 1999] : chute ($r = -1{,}0$), objectif ($r = +1{,}0$), collision avec un mur ($r = -0{,}1$), déplacement ordinaire ($r = 0{,}0$).

1.2 Cas d'étude

Le Tableau 1 et la Figure 1 présentent les trois configurations retenues.

TABLE 1 – Configurations des trois cas d'étude.

	Facile	**Moyen**	**Difficile**
Taille de la grille	4×4	4×4	6×6
`is_slippery`	Non	Oui	Oui
Nombre de trous	3	3	4
Positionnement	Colonne droite	Colonne droite	Rangée centrale

Facile (4×4, déterministe, 3 trous en colonne). Référence sans bruit : toute stratégie TD doit converger vers un taux de chutes nul. Valide l'implémentation et établit une borne supérieure de performance.

Moyen (4×4, stochastique, 3 trous en colonne). Topologie identique à *Facile* ; seul `is_slippery` change. Isole proprement l'effet de la stochasticité sur la sécurité.

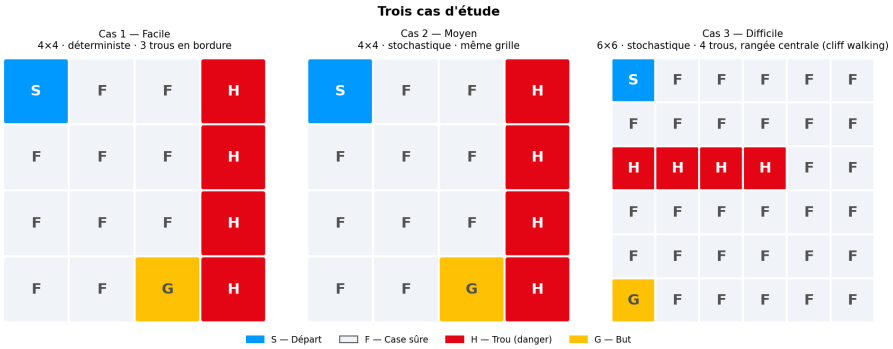

FIGURE 1 – Visualisation des trois environnements. `S` : départ, `G` : objectif, `H` : trou, `F` : case libre.

Difficile (6×6, stochastique, 4 trous contigus en rangée centrale). La rangée `HHHHFF` crée une barrière horizontale analogue au *cliff walking* [Sutton and Barto, 2018, chap. 6]. Deux trajectoires coexistent : un chemin court risqué longeant les trous et un long détour sûr par les colonnes droites. La grille 6×6 assure que ce détour est significativement plus long, condition nécessaire pour observer la divergence *off-policy*/*on-policy*.

2 Stratégies considérées

Deux stratégies de différence temporelle (TD) sont sélectionnées comme baselines : Q-learning et SARSA. Ces méthodes ne disposent d'aucun mécanisme conçu explicitement pour éviter les situations dangereuses, établissant ainsi une limite de référence. Le choix de méthodes tabulaires (plutôt que DQN [Mnih et al., 2015] ou PPO) se justifie par la taille réduite de l'espace d'états (16 et 36 états) : les différences observées reflètent directement les propriétés intrinsèques des algorithmes. Q-learning et SARSA forment la paire canonique *off-policy*/*on-policy* dont les comportements face aux obstacles sont directement prédits par la théorie [Sutton and Barto, 2018].

Q-learning [Watkins and Dayan, 1992] est une méthode *off-policy* dont la règle de mise à jour est :

$$Q(s,a) \leftarrow Q(s,a) + \alpha\big[r + \gamma \max_{a'} Q(s',a') - Q(s,a)\big]. \tag{1}$$

En ciblant toujours le maximum, Q-learning peut sous-estimer le risque réel et préférer le chemin court risqué dans des environnements à obstacles groupés.

SARSA [Rummery and Niranjan, 1994] est une méthode *on-policy* qui utilise l'action réellement sélectionnée :

$$Q(s,a) \leftarrow Q(s,a) + \alpha\big[r + \gamma\, Q(s',a') - Q(s,a)\big]. \tag{2}$$

Puisque a' peut être aléatoire (avec probabilité ε), SARSA intègre le coût de l'exploration dans ses estimations, ce qui le rend naturellement plus prudent près des obstacles.

Trois travaux en Safe Reinforcement Learning ont été identifiés, chacun proposant un mécanisme distinct d'intégration de la sécurité.

Tout d'abord, **Model-based Safe Deep RL via a Constrained Proximal Policy Optimization Algorithm** [Jayant and Bhatnagar, 2022] étend PPO en couplant un modèle de dynamique appris avec une optimisation sous contraintes de coût cumulé (CMDP). L'agent anticipe les conséquences futures avant d'agir, offrant des garanties théoriques solides, mais cette méthode repose fondamentalement sur l'approximation de fonction et l'apprentissage profond, la rendant peu adaptée à un cadre tabulaire.

Ensuite, **Safe RL by Imagining the Near Future** [Thomas et al., 2022] adopte, lui, une stratégie prédictive : l'agent apprend un modèle du monde et simule des trajectoires futures avant d'agir pour évaluer le risque à court terme. Cette anticipation évite certaines erreurs a priori, mais le modèle neuronal et la génération de trajectoires imaginées sont difficilement transposables à un cadre où les transitions sont déjà exactement connues.

Enfin, **The Fear Field Framework** [Odriozola-Olalde et al., 2025] propose un shielding adaptatif pour environnements stochastiques discrets. La méthode maintient dynamiquement une zone tampon autour des états dangereux, appelée *fear field*, dont le rayon s'élargit lors de transitions imprévues et se réduit en l'absence d'incident. Un mécanisme d'exploration adaptative augmente ε lorsqu'un comportement de boucle est détecté.

Parmi ces trois approches, le **principe du shielding adaptatif** proposé par Fear Field est retenu comme stratégie principale. C'est l'approche la plus récente (2025), directement appliquée à `FrozenLake-v1` par ses auteurs [Odriozola-Olalde et al., 2025], et la seule adaptable à un cadre tabulaire sans réseau de neurones. Son mécanisme répond

précisément au défi central de l'étude : la stochasticité de `is_slippery=True`, où les glissades imprévues rendent les politiques naïves vulnérables.

Notre adaptation tabulaire remplace le modèle neuronal original par la table de transitions exacte de Gymnasium (`env.unwrapped.P`), éliminant tout apprentissage auxiliaire tout en préservant l'idée centrale du shielding prédictif. Nous ne conservons pas le mécanisme d'exploration adaptative ni le rétrécissement progressif du rayon, ces aspects introduisant des hyperparamètres supplémentaires hors du cadre de cette étude.

Avant chaque sélection d'action, l'ensemble des actions admissibles est déterminé :

$$\mathcal{A}_{\text{safe}}(s) = \{a \in \mathcal{A} \mid \forall\,(p,\, s',\, r,\, d) \in P(s,\, a), \quad p > 0 \Rightarrow s' \notin \mathcal{H}\} \tag{3}$$

où $\mathcal{H}$ est l'ensemble des états-trous. Si $\mathcal{A}_{\text{safe}}(s) = \emptyset$, toutes les actions sont autorisées (cas de repli). La sélection ε-greedy est restreinte à cet ensemble :

$$a_t = \begin{cases} \text{Uniform}(\mathcal{A}_{\text{safe}}(s_t)) & \text{avec probabilité } \varepsilon \\ \arg\max\limits_{a \in \mathcal{A}_{\text{safe}}(s_t)} Q(s_t,\, a) & \text{sinon} \end{cases} \tag{4}$$

La mise à jour TD demeure identique à Q-learning standard. La différence fondamentale est que l'exploration et l'exploitation sont toutes deux contraintes à $\mathcal{A}_{\text{safe}}(s)$, empêchant toute sélection d'une action menant vers un trou pendant l'apprentissage.

3 Méthodologie expérimentale

Librairies : l'environnement est fourni par Gymnasium 1.2.3 [Towers et al., 2024]. Les trois algorithmes sont implémentés en Python/NumPy 2.2.6, sans recours à Stable-Baselines3 [Raffin et al., 2021], afin de contrôler précisément les mises à jour TD et la construction du shield.

Hyper-paramètres : les trois algorithmes partagent les mêmes hyper-paramètres : $\gamma = 0{,}99$, $\alpha_0 = 0{,}5$ [Sutton and Barto, 2018], décroissance $0{,}9995$ pour α et ε jusqu'aux minima $\alpha_{\min} = 0{,}01$ et $\varepsilon_{\min} = 0{,}05$ (atteints après $\approx 6\,000$ épisodes). Le Q-learning blindé n'introduit aucun hyper-paramètre supplémentaire : le shield est construit directement depuis `env.unwrapped.P`.

Paramètres expérimentaux : chaque configuration est entraînée sur 20 000 épisodes (maximum 200 pas). Les expériences sont répétées avec $n = 10$ graines indépendantes. L'évaluation finale utilise la politique greedy ($\varepsilon = 0$, sans shield) sur 500 épisodes.

Indicateurs de performance :

- **Récompense et taux de chutes durant l'entraînement** (moyenne mobile, fenêtre 500 épisodes) : convergence et sécurité au cours de l'apprentissage.
- **Taux de boucles durant l'entraînement** : fraction d'épisodes terminés par dépassement de la limite de pas.
- **Taux d'états dangereux à l'évaluation** : fraction de pas dans une case adjacente à un trou lors de la politique greedy.
- **Taux de chemins sécurisés à l'évaluation** : fraction des épisodes réussis dont la trajectoire chevauche à $\geq 50\,\%$ le chemin optimal de sécurité calculé par Dijkstra [Dijkstra, 1959] (cas Difficile uniquement).

4 Résultats

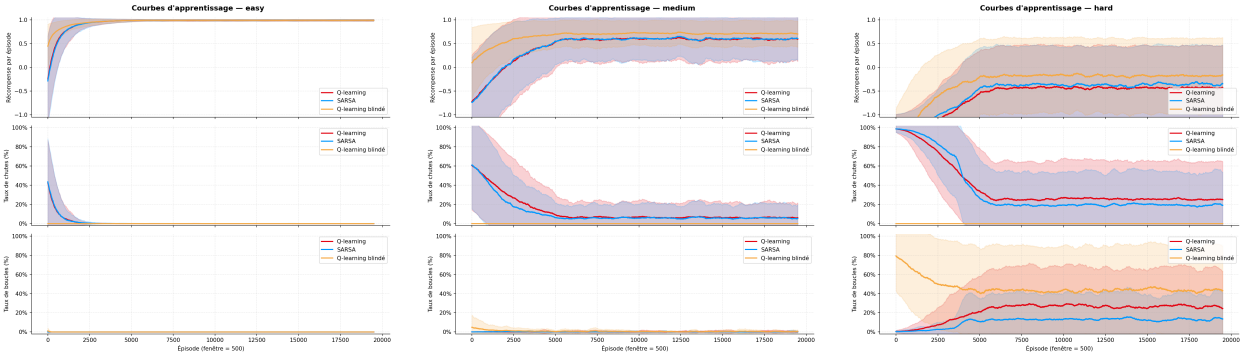

(a) **Facile** : convergence rapide vers 0 % de chutes. Le shield n'apporte aucun avantage dans l'environnement déterministe.

(b) **Moyen** : la stochasticité maintient un risque résiduel. Le shield réduit les chutes en début d'apprentissage par rapport aux baselines.

(c) **Difficile** : SARSA et le shield réduisent davantage les chutes que Q-learning en fin d'apprentissage.

FIGURE 2 – Courbes d'apprentissage (récompense, chutes, boucles). Bande colorée : $\pm$ un écart-type sur 10 répétitions. *Facile* valide l'implémentation ; *Moyen* isole la stochasticité ; *Difficile* révèle la divergence *off-policy*/*on-policy*.

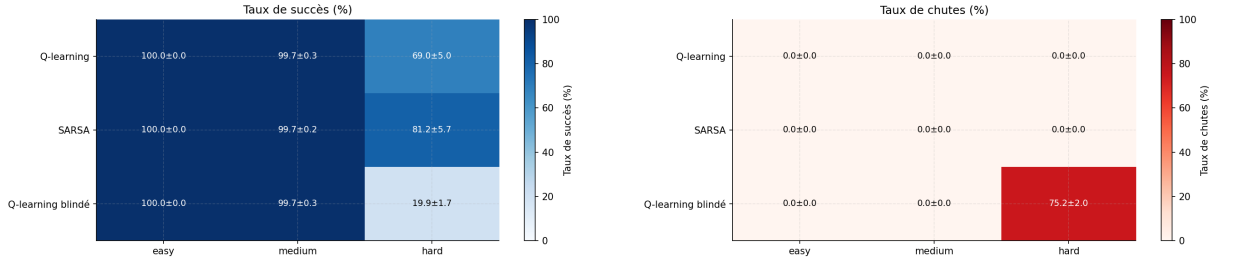

(a) Taux de succès à l'évaluation.

(b) Taux de chutes à l'évaluation.

FIGURE 3 – Vue d'ensemble : évaluation greedy sans shield, 500 épisodes. Le taux de chutes élevé du Q-learning blindé sur *Difficile* est absent sur les deux autres cas.

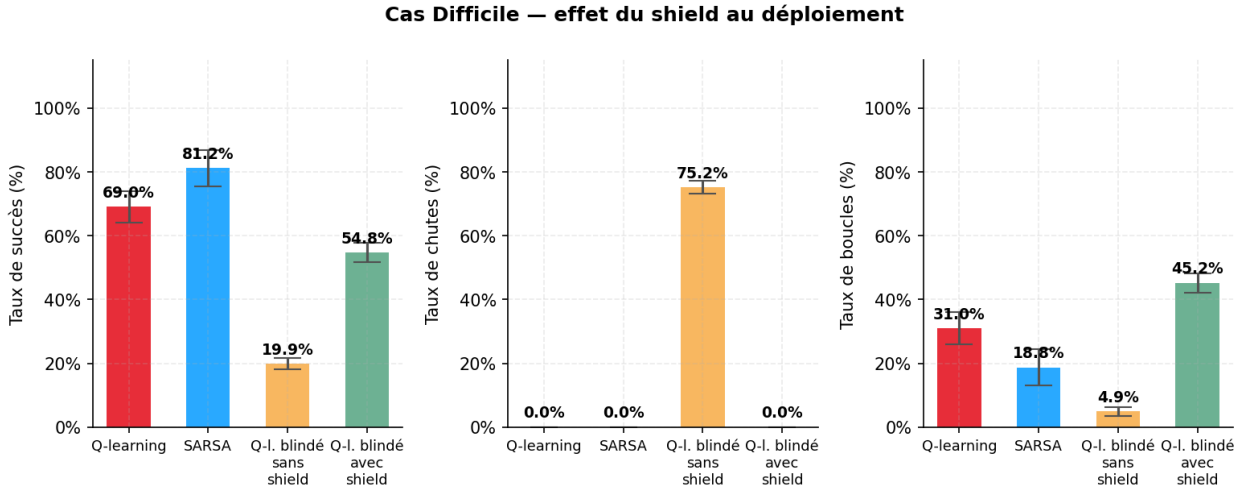

FIGURE 4 – Cas **Difficile** : effet du shield au déploiement. Le Q-learning blindé est entraîné de manière identique dans les deux cas ; seule la politique d'évaluation change selon que le shield est maintenu ou non à l'inférence. Le shield actif élimine les chutes (0,0%) mais transfère une partie de l'échec vers les boucles (45,2%).

La Figure 4 complète les vues d'ensemble sans les dupliquer : sur *Facile* et *Moyen*, activer le shield à l'inférence ne modifie pratiquement pas les résultats, alors que sur *Difficile* l'effet devient structurel. Avec la même table Q, le Q-learning blindé passe de $19{,}9\%$ de succès et $75{,}2\%$ de chutes sans shield à $54{,}8\%$ de succès, $0{,}0\%$ de chutes et $45{,}2\%$ de boucles avec shield. Ce résultat montre que le mécanisme de sécurité n'améliore pas seulement l'exploration ; il modifie aussi le compromis sécurité/performance lorsqu'il reste actif au déploiement.

TABLE 2 – Indicateurs d'évaluation finale (politique greedy sans shield, 500 épisodes, moyenne $\pm$ écart-type, 10 répétitions). Chemin sûr : chevauchement $\geq 50\%$ avec Dijkstra (Difficile uniquement).

		Facile	**Moyen**	**Difficile**
Q-learning	Succès	$100{,}0 \pm 0{,}0\%$	$99{,}7 \pm 0{,}3\%$	$69{,}0 \pm 5{,}0\%$
	Chutes	$0{,}0 \pm 0{,}0\%$	$0{,}0 \pm 0{,}0\%$	$0{,}0 \pm 0{,}0\%$
	Boucles	$0{,}0 \pm 0{,}0\%$	$0{,}3 \pm 0{,}3\%$	$31{,}0 \pm 5{,}0\%$
	Danger	$20{,}0\%$	$28{,}5\%$	$29{,}9\%$
	Chemin sûr	---	---	$60{,}1 \pm 2{,}9\%$
SARSA	Succès	$100{,}0 \pm 0{,}0\%$	$99{,}7 \pm 0{,}2\%$	$81{,}2 \pm 5{,}7\%$
	Chutes	$0{,}0 \pm 0{,}0\%$	$0{,}0 \pm 0{,}0\%$	$0{,}0 \pm 0{,}0\%$
	Boucles	$0{,}0 \pm 0{,}0\%$	$0{,}3 \pm 0{,}2\%$	$18{,}8 \pm 5{,}7\%$
	Danger	$20{,}0\%$	$27{,}7\%$	$25{,}9\%$
	Chemin sûr	---	---	$70{,}4 \pm 2{,}9\%$
Q-l. blindé	Succès	$100{,}0 \pm 0{,}0\%$	$99{,}7 \pm 0{,}3\%$	$19{,}9 \pm 1{,}7\%$
	Chutes	$0{,}0 \pm 0{,}0\%$	$0{,}0 \pm 0{,}0\%$	$75{,}2 \pm 2{,}2\%$
	Boucles	$0{,}0 \pm 0{,}0\%$	$0{,}3 \pm 0{,}3\%$	$4{,}9 \pm 1{,}4\%$
	Danger	$20{,}0\%$	$28{,}6\%$	$30{,}4\%$
	Chemin sûr	---	---	$68{,}7 \pm 2{,}6\%$

Sur Facile et Moyen, les trois stratégies sont équivalentes à l'évaluation. Sur Difficile, le Q-learning blindé obtient seulement $19{,}9\%$ de succès avec $75{,}2\%$ de chutes, bien en dessous de SARSA ($81{,}2\%$) et de Q-learning ($69{,}0\%$). Son taux de boucles ($4{,}9\%$) est pourtant le plus faible ; c'est la politique greedy sans shield qui marche fréquemment vers les trous.

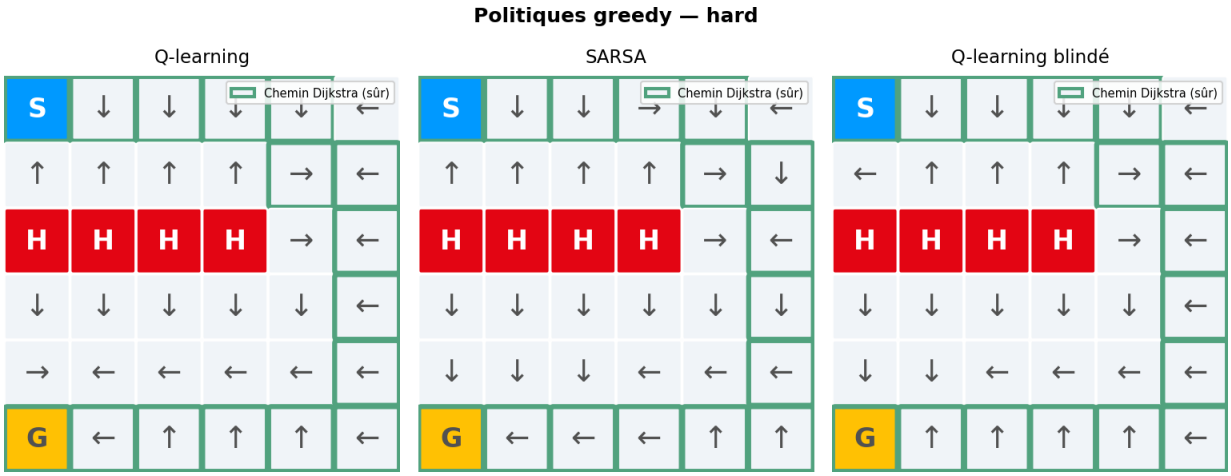

FIGURE 5 – Politiques greedy sur le cas Difficile (10 répétitions). Le contour vert délimite le chemin Dijkstra. SARSA emprunte systématiquement le détour sûr. Le Q-learning blindé présente des flèches incohérentes dans la zone proche de la barrière, signe d'une table Q mal calibrée sans shield actif.

5 Discussion

Liens avec la littérature : sur le cas Difficile, SARSA emprunte le détour sûr plus souvent que Q-learning ($70{,}4\%$ contre $60{,}1\%$), confirmant le phénomène du *cliff walking* prédit par la théorie [Sutton and Barto, 2018, chap. 6] : la mise à jour *on-policy* intègre naturellement le coût de l'exploration dans les estimations de valeur. La réduction des chutes par le shield pendant l'entraînement est cohérente avec le principe Fear Field [Odriozola-Olalde et al., 2025]. Cependant, l'implémentation originale maintient le shield au déploiement, alors que notre protocole principal l'évalue d'abord en politique greedy sans shield. La Figure 4 montre que cette distinction de protocole change qualitativement l'interprétation du résultat sur *Difficile*.

Explication des résultats : sur *Facile* et *Moyen*, les trois stratégies convergent vers des politiques équivalentes : la topologie reste simple et la politique greedy finale évite déjà les trous, avec ou sans shield au déploiement. Le cas *Difficile* est d'une nature différente. D'abord, la contrainte $\mathcal{A}_{\text{safe}}(s)$ retire de l'exploration les actions qui mèneraient dans un trou avec probabilité non nulle ; leurs Q-valeurs restent donc peu ou pas informées. Ensuite, Q-learning demeure *off-policy* : la mise à jour utilise $\max_{a'} Q(s', a')$, y compris pour des actions rarement ou jamais jouées à cause du masquage. On obtient ainsi une table Q partiellement incohérente près de la barrière centrale, où certaines actions non testées conservent une valeur artificiellement compétitive. Enfin, pour plusieurs états adjacents à la barrière, $\mathcal{A}_{\text{safe}}(s) = \emptyset$ à cause de la stochasticité : le repli autorise alors toutes les actions exactement dans la zone la plus risquée, ce qui détériore encore l'estimation locale. Sans shield à l'évaluation, la politique greedy peut donc sélectionner des actions dont la dangerosité n'a jamais été réellement internalisée, d'où les $75{,}2\%$ de chutes observés.

Le comportement *avec* shield au déploiement confirme cette lecture. En maintenant le filtrage à l'inférence, les chutes tombent à $0{,}0\%$, ce qui montre que le mécanisme de sécurité remplit bien son objectif de court terme : empêcher l'entrée dans les états dangereux. En revanche, le taux de boucles monte à $45{,}2\%$ et le succès plafonne à $54{,}8\%$. Le shield ne corrige donc pas la qualité de la table Q ; il transforme une partie des échecs par chute en échecs par incapacité à progresser. Autrement dit, le modèle tabulaire blindé obtenu ici garantit mieux la sécurité *pas à pas*, mais pas l'efficacité globale de la navigation.

Réflexion : SARSA offre le meilleur rapport qualité-sécurité sans mécanisme dédié : sa mise à jour *on-policy* produit la meilleure politique finale sur *Difficile* ($81{,}2\%$ de succès, $25{,}9\%$ de proximité aux trous) parce qu'elle internalise naturellement le coût de l'exploration. Le shield tabulaire, lui, est computationnellement léger et très efficace pour interdire immédiatement les transitions dangereuses, mais il introduit une tension structurelle entre *sûreté locale* et *progrès global*. Plus le filtrage est conservateur dans un environnement glissant, plus il protège contre les trous ; mais plus il risque aussi d'enfermer l'agent dans des comportements prudents mais improductifs. Cette tension explique pourquoi la version *avec shield* réduit les chutes à zéro sans rattraper les performances de SARSA.

D'un point de vue pratique, cette expérience souligne aussi une limite importante de notre simplification : le shield repose ici sur la table exacte $P(s'|s, a)$ fournie par Gymnasium. Dans un système réel, cette connaissance devrait être apprise ou approximée ; les erreurs de modèle déplaceraient encore le compromis observé. Deux prolongements naturels seraient donc (1) de maintenir explicitement le shield au déploiement lorsqu'une garantie de sûreté prime sur le taux de succès, et (2) de remplacer la contrainte stricte ($p > 0$) par un seuil probabiliste ($p > \theta$) afin de réduire la sur-conservativité dans les zones où la glissade rend toute action localement risquée.

Message général au client : réduire les situations dangereuses pendant l'apprentissage est atteint par les trois stratégies sur les cas simples, mais l'environnement *Difficile* révèle qu'il faut distinguer *apprendre prudemment* de *agir sûrement au déploiement*. Le Q-learning blindé simplifié n'est pas une meilleure politique finale en soi : sans shield à l'inférence, il chute massivement ; avec shield, il devient sûr mais plus souvent bloqué. La recommandation est donc d'utiliser **SARSA** comme base robuste pour des environnements stochastiques à obstacles groupés, et de réserver un shield maintenu au déploiement aux contextes où l'élimination des chutes est prioritaire même au prix d'un plus grand nombre de boucles.

Références

Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U. Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, et al. Gymnasium : A standard interface for reinforcement learning environments. *arXiv preprint arXiv :2407.17032*, 2024.

Andrew Y. Ng, Daishi Harada, and Stuart J. Russell. Policy invariance under reward transformations : Theory and application to reward shaping. In *Proceedings of the Sixteenth International Conference on Machine Learning*, pages 278–287, 1999.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning : An Introduction*. MIT Press, Cambridge, MA, 2 edition, 2018.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540) :529–533, 2015.

Christopher J. C. H. Watkins and Peter Dayan. Q-learning. *Machine Learning*, 8(3–4) :279–292, 1992.

Gavin A. Rummery and Mahesan Niranjan. On-line q-learning using connectionist systems. Technical Report CUED/F-INFENG/TR 166, University of Cambridge, 1994.

Ashish Kumar Jayant and Shalabh Bhatnagar. Model-based safe deep reinforcement learning via a constrained proximal policy optimization algorithm. *arXiv preprint arXiv :2210.07573*, 2022.

Garrett Thomas, Yuping Luo, and Tengyu Ma. Safe reinforcement learning by imagining the near future. *arXiv preprint arXiv :2202.07789*, 2022.

Haritz Odriozola-Olalde, Maider Zamalloa, Nestor Arana-Arexolaleiba, and Jon Pérez-Cerrolaza. Towards robust shielded reinforcement learning through adaptive constraints and exploration : The fear field framework. *Engineering Applications of Artificial Intelligence*, 144 :110055, 2025.

Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-Baselines3 : Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268) :1–8, 2021.

Edsger W. Dijkstra. A note on two problems in connexion with graphs. *Numerische Mathematik*, 1 :269–271, 1959.