ANALYSE PRÉLIMINAIRE — APPRENTISSAGE PAR RENFORCEMENT SUR *FrozenLake*

A PREPRINT

Ibrahim R. HADJ-ARAB
Faculté des sciences et de génie
Université Laval
ibrahim-rabah.hadj-arab.1@ulaval.ca

Khalil EN NOUAARY
Faculté des sciences et de génie
Université Laval
khalil.en-nouaary.1@ulaval.ca

28 mars 2026

Code source disponible à : `https://github.com/Ribraba/IFT-7201-Projet`

1 Cas d'étude

1.1 Composantes de l'environnement

FrozenLake-v1 [Towers et al., 2024] est un environnement de navigation en grille $N \times N$. L'espace d'états est l'ensemble des N^2 cases ; l'espace d'actions contient quatre déplacements (haut, bas, gauche, droite). Trois composantes peuvent être manipulées pour moduler la difficulté de l'environnement et l'exposition aux situations dangereuses :

- **Degré de stochasticité.** Le paramètre `is_slippery` contrôle la dynamique de transition. Lorsque activé, chaque action entraîne le déplacement souhaité avec probabilité $1/3$ et l'un des deux déplacements perpendiculaires avec probabilité $1/3$ chacun, rendant l'environnement non-déterministe.
- **Nombre de situations dangereuses.** Les cases de type `H` (trous) constituent les situations dangereuses. Augmenter leur nombre réduit la surface praticable et multiplie les risques de chute.
- **Positionnement des situations dangereuses.** Regrouper les trous de façon contiguë (ex. rangée horizontale) crée un obstacle de type falaise, forçant l'agent à choisir entre un chemin court risqué et un détour sûr.

La fonction de récompense est mise en forme pour accélérer la propagation du signal de danger : chute dans un trou ($r = -1{,}0$), atteinte de l'objectif ($r = +1{,}0$), collision avec un mur ($r = -0{,}1$), déplacement ordinaire ($r = 0{,}0$).

1.2 Cas d'étude

Le Tableau 1 et la Figure 1 présentent les trois configurations retenues.

TABLE 1 – Configurations des trois cas d'étude.

	Facile	**Moyen**	**Difficile**
Taille de la grille	4×4	4×4	6×6
`is_slippery`	Non	Oui	Oui
Nombre de trous	3	3	4
Positionnement	Colonne droite	Colonne droite	Rangée centrale

Facile (4×4, déterministe, 3 trous en colonne). Les transitions sont déterministes. Ce cas sert de référence : en l'absence de bruit, toute stratégie TD doit converger vers un taux de chutes nul. Il valide l'implémentation et établit une borne supérieure de performance.

Moyen (4×4, stochastique, 3 trous en colonne). Même topologie que *Facile*, mais avec `is_slippery=True`. Ce cas isole l'effet de la stochasticité : les glissades aléatoires peuvent précipiter l'agent vers un trou même si son action choisie était sûre, quantifiant ainsi l'impact du non-déterminisme sur la sécurité durant l'apprentissage.

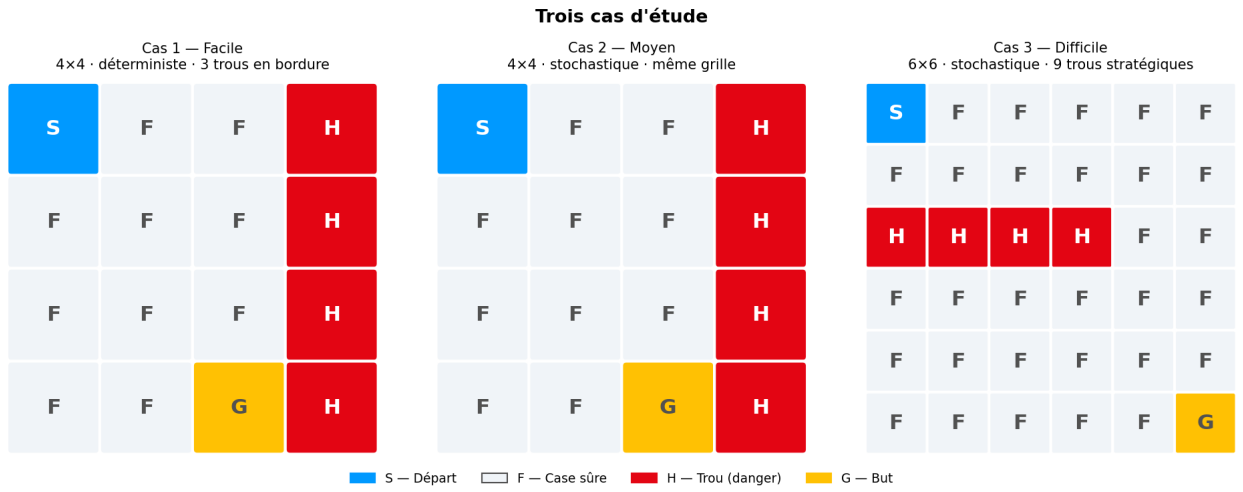

FIGURE 1 – Visualisation des trois environnements. `S` : départ, `G` : objectif, `H` : trou (situation dangereuse), `F` : case libre.

Difficile (6×6, stochastique, 4 trous contigus en rangée centrale). La rangée `HHHHFF` crée une barrière partielle analogue au problème du *cliff walking* [Sutton and Barto, 2018, chap. 6] : il existe un chemin court mais risqué longeant les trous et un long chemin sûr par les colonnes de droite. Ce cas combine les effets de la stochasticité, d'un nombre accru de trous et d'un positionnement hostile, poussant les deux stratégies à exhiber des comportements divergents face au risque.

2 Stratégies considérées

Deux stratégies de différence temporelle (TD) sont sélectionnées comme baselines. Il s'agit de méthodes standard ne disposant d'aucun mécanisme conçu explicitement pour éviter les situations dangereuses, ce qui permet de mesurer la limite inférieure de sécurité que tout mécanisme futur devra dépasser.

Q-learning [Watkins and Dayan, 1992] est une méthode *off-policy* dont la règle de mise à jour repose sur la valeur maximale de l'état suivant :

$$Q(s,a) \leftarrow Q(s,a) + \alpha\big[r + \gamma \max_{a'} Q(s',a') - Q(s,a)\big]. \tag{1}$$

Cette mise à jour optimiste suppose que la politique optimale sera suivie dans le futur, indépendamment de l'exploration en cours. Dans des environnements à obstacles groupés, cette hypothèse peut conduire à sous-estimer le risque réel de chute et à préférer le chemin court risqué.

SARSA [Rummery and Niranjan, 1994] est une méthode *on-policy* qui utilise l'action réellement sélectionnée selon la politique ε-greedy courante :

$$Q(s,a) \leftarrow Q(s,a) + \alpha\big[r + \gamma\, Q(s',a') - Q(s,a)\big]. \tag{2}$$

Puisque a' peut être une action aléatoire (avec probabilité ε), SARSA intègre le coût de l'exploration dans ses estimations. On s'attend donc à ce qu'il apprenne à éviter davantage les cases proches des trous, au prix d'une propagation plus lente du signal de danger en début d'apprentissage. La confrontation de ces deux comportements opposés face au risque est la principale motivation de leur sélection.

3 Méthodologie expérimentale

Librairies. L'environnement est fourni par Gymnasium 1.2.3 [Towers et al., 2024]. Q-learning et SARSA sont implémentés directement en Python/NumPy 2.2.6, sans recours à Stable-Baselines3 [Raffin et al., 2021], afin de contrôler précisément les mises à jour TD.

Hyper-paramètres. Les deux algorithmes partagent : $\gamma = 0{,}99$ (horizon long, adapté aux trajectoires multi-étapes jusqu'à l'objectif), $\alpha_0 = 0{,}5$ (valeur standard pour les méthodes TD tabulaires [Sutton and Barto, 2018]), décroissance $0{,}9995$ pour α et ε jusqu'aux minima $\alpha_{\min} = 0{,}01$ et $\varepsilon_{\min} = 0{,}05$. Ce taux de décroissance amène ε à son minimum

après $\approx 6\,000$ épisodes, assurant une phase d'exploration large suivie d'une exploitation progressive sur les 14 000 épisodes restants.

Paramètres expérimentaux. Chaque configuration est entraînée sur 20 000 épisodes, avec un maximum de 200 pas par épisode. Les expériences sont répétées avec $n = 10$ graines indépendantes (graines 0 à 9) pour produire des intervalles de confiance (moyenne $\pm$ écart-type). L'évaluation finale utilise la politique greedy ($\varepsilon = 0$) sur 500 épisodes.

Indicateurs de performance. L'étude vise à évaluer la sécurité *durant* l'apprentissage et non uniquement sur la politique finale. Trois indicateurs sont mesurés :

- **Taux de chutes durant l'entraînement** : fraction d'épisodes terminés dans un trou (lissé sur 500 épisodes). Mesure la sécurité au cours de l'apprentissage.
- **Récompense cumulée durant l'entraînement** : indicateur de convergence de la politique.
- **Taux d'états dangereux à l'évaluation** : fraction de pas de temps passés dans une case adjacente à un trou lors de l'évaluation greedy. Quantifie le risque de proximité avec les obstacles de la politique finale.

4 Résultats

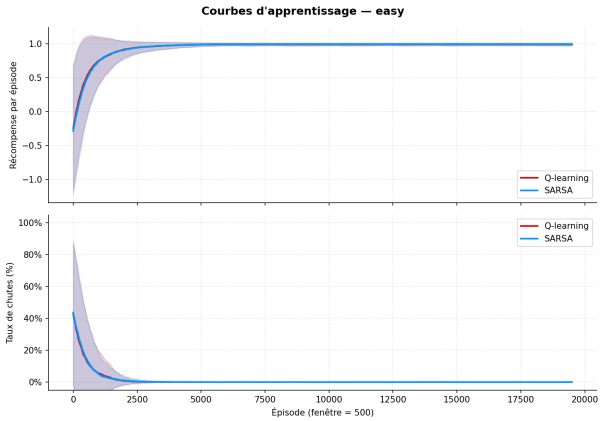

(a) **Facile** — Convergence vers 0% de chutes dès $\approx 3\,000$ épisodes. Q-learning converge légèrement plus vite grâce à ses mises à jour optimistes. Valide les implémentations en environnement déterministe.

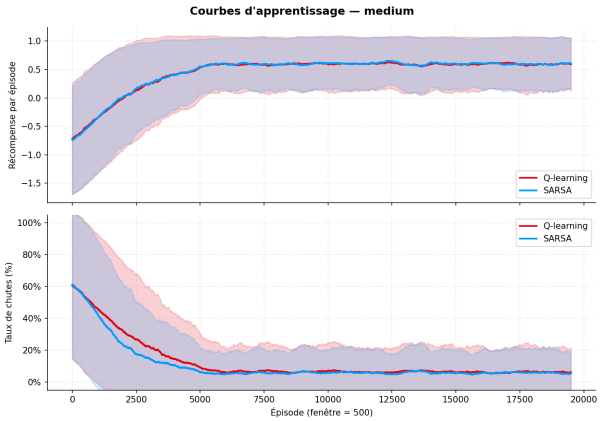

(b) **Moyen** — La stochasticité fait bondir le taux de chutes initial à $\approx 50\%$ (contre $\approx 16\%$ en Facile). Le taux ne converge pas vers zéro : $\varepsilon_{\min} = 5\%$ combiné aux glissades maintient un risque irréductible.

FIGURE 2 – Courbes d'apprentissage — cas Facile et Moyen. La bande colorée représente $\pm$ un écart-type sur 10 répétitions.

Le Tableau 2 présente le taux d'états dangereux à l'évaluation. Sur le cas Difficile, SARSA réduit également la proximité aux trous ($27{,}4\% \pm 1{,}4\%$ contre $32{,}8\% \pm 1{,}1\%$ pour Q-learning), confirmant que son comportement plus conservateur se traduit par une politique finale qui s'écarte davantage des obstacles.

TABLE 2 – Taux d'états dangereux à l'évaluation (moyenne $\pm$ écart-type, 10 répétitions).

	Facile	**Moyen**	**Difficile**
Q-learning	$20{,}0 \pm 0{,}0\%$	$28{,}5 \pm 1{,}6\%$	$32{,}8 \pm 1{,}1\%$
SARSA	$20{,}0 \pm 0{,}0\%$	$27{,}7 \pm 0{,}6\%$	$27{,}4 \pm 1{,}4\%$

Ces résultats montrent que Q-learning converge plus rapidement mais adopte une politique plus risquée en environnement stochastique avec obstacles groupés, tandis que SARSA, plus conservateur, réduit davantage les chutes et la proximité aux trous une fois l'exploration amortie. Ces limitations des stratégies sans mécanisme de sécurité explicite motivent l'introduction d'une telle stratégie dans le rapport final.

Références

Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U. Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, et al. Gymnasium : A standard interface for reinforcement learning

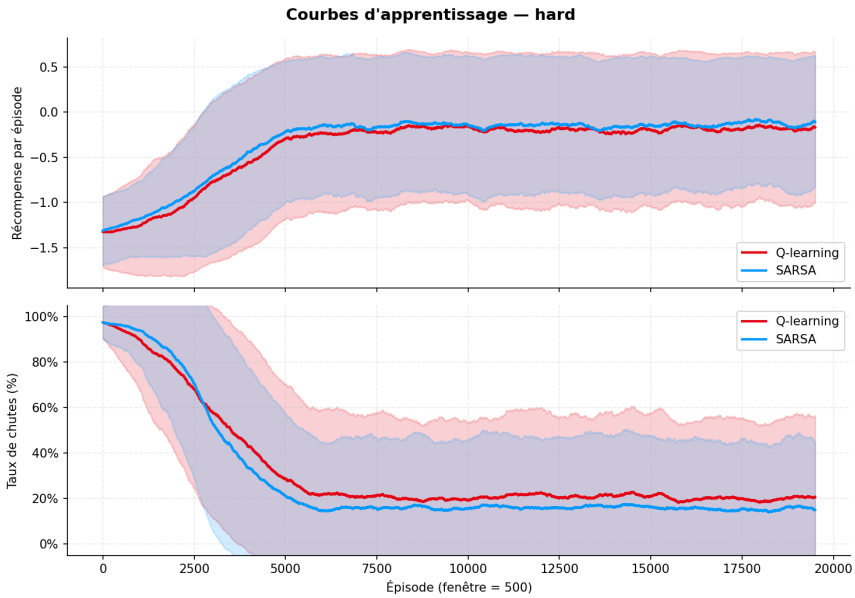

FIGURE 3 – **Difficile** — Les courbes se croisent, reproduisant le phénomène de *cliff walking* [Sutton and Barto, 2018]. SARSA chute davantage en début d'apprentissage ($94{,}1\%$ vs $91{,}3\%$) mais converge vers un taux de chutes plus faible ($15{,}2\%$ vs $19{,}9\%$) : la mise à jour *on-policy* intègre le coût de l'exploration et pousse l'agent vers le détour sûr.

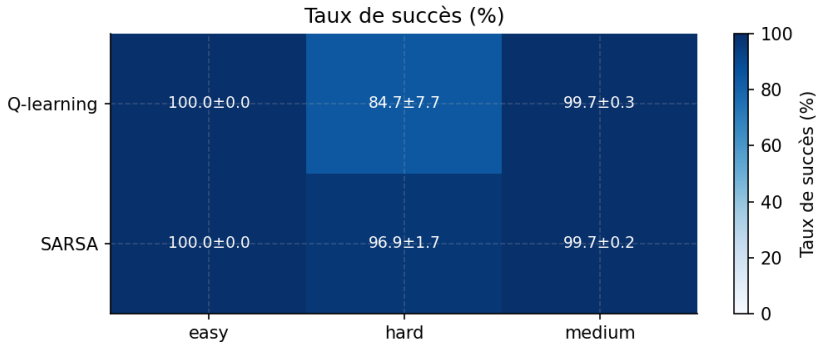

FIGURE 4 – Taux de succès à l'évaluation finale (politique greedy, 500 épisodes). Le taux de chutes est nul pour les deux stratégies : les échecs correspondent à des *timeouts*. La comparaison de sécurité pertinente reste le taux de chutes *durant* l'entraînement (Fig. 2–3).

environments. *arXiv preprint arXiv :2407.17032*, 2024.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning : An Introduction*. MIT Press, Cambridge, MA, 2 edition, 2018.

Christopher J. C. H. Watkins and Peter Dayan. Q-learning. *Machine Learning*, 8(3–4) :279–292, 1992.

Gavin A. Rummery and Mahesan Niranjan. On-line q-learning using connectionist systems. Technical Report CUED/F-INFENG/TR 166, University of Cambridge, 1994.

Antonin Raffin, Ashley Hill, Adam Gleave, Anssi Kanervisto, Maximilian Ernestus, and Noah Dormann. Stable-Baselines3 : Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268) :1–8, 2021.